食物攝取與症狀：資料整理與 MCA 探索

1 報告說明

本報告整合資料清理、資料概覽、方法選擇及 MCA 分析紀錄。分析單位為 55 位受試者；完全相同的資料列依使用者決定保留為不同受試者。主要分析問題是食物攝取與症狀的探索性關聯，不作因果推論。

最終 MCA 設定為六種食物作為 active variables、五項症狀作為 supplementary variables。Age 排除，Time 保留但忽略。`method_taxonomy.json` 維持原樣，沒有擴充。

```
qmd_dir <- getwd()
setwd("..")
source(".Rprofile")
```

```
- The project is out-of-sync -- use `renv::status()` for details.
```

```
setwd(qmd_dir)
library(FactoMineR)
library(factoextra)
library(vcd)
library(arrow)
library(ggplot2)
data <- as.data.frame(arrow::read_parquet("poison_cleaned.parquet"))
```

2 一、資料清理紀錄

2.1 1. 資料匯入

- 原始檔名：`poison.csv`
- 檔案格式：CSV（UTF-8 BOM）
- 載入狀態：成功，以 pandas 載入
- 觀測值數：55
- 變數數：15

2.1.1 資料預覽（原始資料前 6 筆）

以下表格以相同列號對應原始資料的前 6 筆。為方便閱讀，欄位分組呈現。

基本資料

列號	Age	Time	Sick	Sex
1	9	22	Sick_y	F

列號	Age	Time	Sick	Sex
2	5	0	Sick_n	F
3	6	16	Sick_y	F
4	9	0	Sick_n	F
5	7	14	Sick_y	M
6	72	9	Sick_y	M

症狀

列號	Nausea	Vomiting	Abdominals	Fever
1	Nausea_y	Vomit_n	Abdo_y	Fever_y
2	Nausea_n	Vomit_n	Abdo_n	Fever_n
3	Nausea_n	Vomit_y	Abdo_y	Fever_y
4	Nausea_n	Vomit_n	Abdo_n	Fever_n
5	Nausea_n	Vomit_y	Abdo_y	Fever_y
6	Nausea_n	Vomit_n	Abdo_y	Fever_y

腹瀉與食物攝取

列號	Diarrhae	Potato	Fish	Mayo
1	Diarrhea_y	Potato_y	Fish_y	Mayo_y
2	Diarrhea_n	Potato_y	Fish_y	Mayo_y
3	Diarrhea_y	Potato_y	Fish_y	Mayo_y
4	Diarrhea_n	Potato_y	Fish_y	Mayo_n
5	Diarrhea_y	Potato_y	Fish_y	Mayo_y
6	Diarrhea_y	Potato_y	Fish_n	Mayo_y

其他食物攝取

列號	Courgette	Cheese	Icecream
1	Courg_y	Cheese_y	Icecream_y

列號	Courgette	Cheese	Icecream
2	Courg_y	Cheese_n	Icecream_y
3	Courg_y	Cheese_y	Icecream_y
4	Courg_y	Cheese_y	Icecream_y
5	Courg_y	Cheese_y	Icecream_y
6	Courg_y	Cheese_y	Icecream_y

2.2 2. 資料特性

2.2.1 2.1 變數分類

變數	資料型態	測量尺度	說明 / 目前判讀
Age	整數	比率型數值	年齡；依使用者確認，單位為歲
Time	整數	比率型數值	時間欄；單位及起算點未知。觀測值為 0–22，且 17 筆 Sick_n 均為 0
Sick	文字類別	二元名目	`Sick_y` / `Sick_n`，依使用者確認表示有病 / 沒病
Sex	文字類別	二元名目	`F` / `M`
Nausea	文字類別	二元名目	`Nausea_y` / `Nausea_n`，是否有噁心（症狀細節暫不展開）
Vomiting	文字類別	二元名目	`Vomit_y` / `Vomit_n`，是否有嘔吐（症狀細節暫不展開）
Abdominals	文字類別	二元名目	`Abdo_y` / `Abdo_n`，是否有該症狀（細部定義暫不展開）
Fever	文字類別	二元名目	`Fever_y` / `Fever_n`，是否有發燒（症狀細節暫不展開）

變數	資料型態	測量尺度	說明 / 目前判讀
Diarrhea	文字類別	二元名目	清理版欄名；原始 CSV 的 `Diarrhae` 為筆誤，值標籤為 `Diarrhea_y` / `Diarrhea_n`
Potato	文字類別	二元名目	`Potato_y` / `Potato_n`，依使用者確認表示有吃 / 沒吃
Fish	文字類別	二元名目	`Fish_y` / `Fish_n`，依使用者確認表示有吃 / 沒吃
Mayo	文字類別	二元名目	`Mayo_y` / `Mayo_n`，依使用者確認表示有吃 / 沒吃；Mayo 的精確餐點名稱未提供
Courgette	文字類別	二元名目	`Courg_y` / `Courg_n`，依使用者確認表示有吃 / 沒吃；Courgette 的精確餐點名稱未提供
Cheese	文字類別	二元名目	`Cheese_y` / `Cheese_n`，依使用者確認表示有吃 / 沒吃
Icecream	文字類別	二元名目	`Icecream_y` / `Icecream_n`，依使用者確認表示有吃 / 沒吃

2.2.2 2.2 資料集特性

- 資料結構：55 筆個體層級調查資料；依 FactoMineR 文件，為小學兒童食物中毒調查資料。是否為同一事件 / 同一群聚，需原始研究背景確認。
- 觀測特性：38 筆 `Sick_y`、17 筆 `Sick_n`；`Sex` 為 F 28 筆、M 27 筆。
- 數值摘要：Age 範圍 4–88，中位數 8；Time 範圍 0–22，中位數 12。Time 的 0 值全數出現在 Sick_n。
- 類別分布：所有症狀與食物欄位均為二元文字類別，依使用者確認，`_y` 表示是（食物欄為有吃、Sick 為有病），`_n` 表示否；食物欄位高度偏向「有吃」：Potato 52/55（94.5%）、Fish 54/55（98.2%）、Mayo 45/55（81.8%）、Courgette 50/55（90.9%）、Cheese 48/55（87.3%）、Icecream 51/55（92.7%）；未吃組人數少，後續比較估計可能不穩定。
- 缺失值：所有 15 欄皆無缺失值（共 0 個）。

- 完全重複列：偵測到 3 組完全重複列（每組各出現 2 次），位於 CSV 第 6/56、5/15、34/50 資料列（含標題列的檔案行號）。使用者確認：相同列視為不同受試者，保留為不同觀測值。
- 年齡值與來源描述可能不一致：8 筆 Age 為 36、45、72、79、82、83、85、88；FactoMineR 文件將樣本描述為小學兒童。可能是資料轉錄、年齡單位 / 欄位定義或來源描述差異，需查證後再決定是否修正或排除。
- 資料型態品質：Age 與 Time 可讀為整數；其餘欄位讀為文字類別。類別值均呈現二元形式，無額外 / 未知標記。

2.3 5. 本次迭代已核准並套用的資料修改

迭代	目標變數	修改內容	理由	使用者核准	對資料集的影響
2	Diarrhae → Diarrhea	僅修正清理版欄名；原始 CSV 不變	修正欄名筆誤，與 `Diarrhea_y` / `Diarrhea_n` 值一致	已核准	55 列、15 欄及欄位值不變，只更動欄名

原始 CSV 未修改。清理版資料集另存為 `poison_cleaned.parquet`；保留 55 列及全部欄位值，將 `Diarrhae` 欄名修正為 `Diarrhea`。使用者確認 Age 單位為歲，且完全相同列視為不同受試者並保留；未刪除任何列，缺失值刪除 / 插補未執行。

3 二、資料視覺化與描述

3.1 執行與重現

本報告的缺失值分析使用原始 `poison.csv`；其他摘要與圖表使用已核准的 `poison_cleaned.parquet`。原始檔未修改。清理版有 55 筆、15 欄；`Diarrhae` 已依前階段決定改名為 `Diarrhea`。

在專案目錄使用虛擬環境執行：

```
.\.venv\Scripts\python.exe .\outputs\data_visualization.py
```

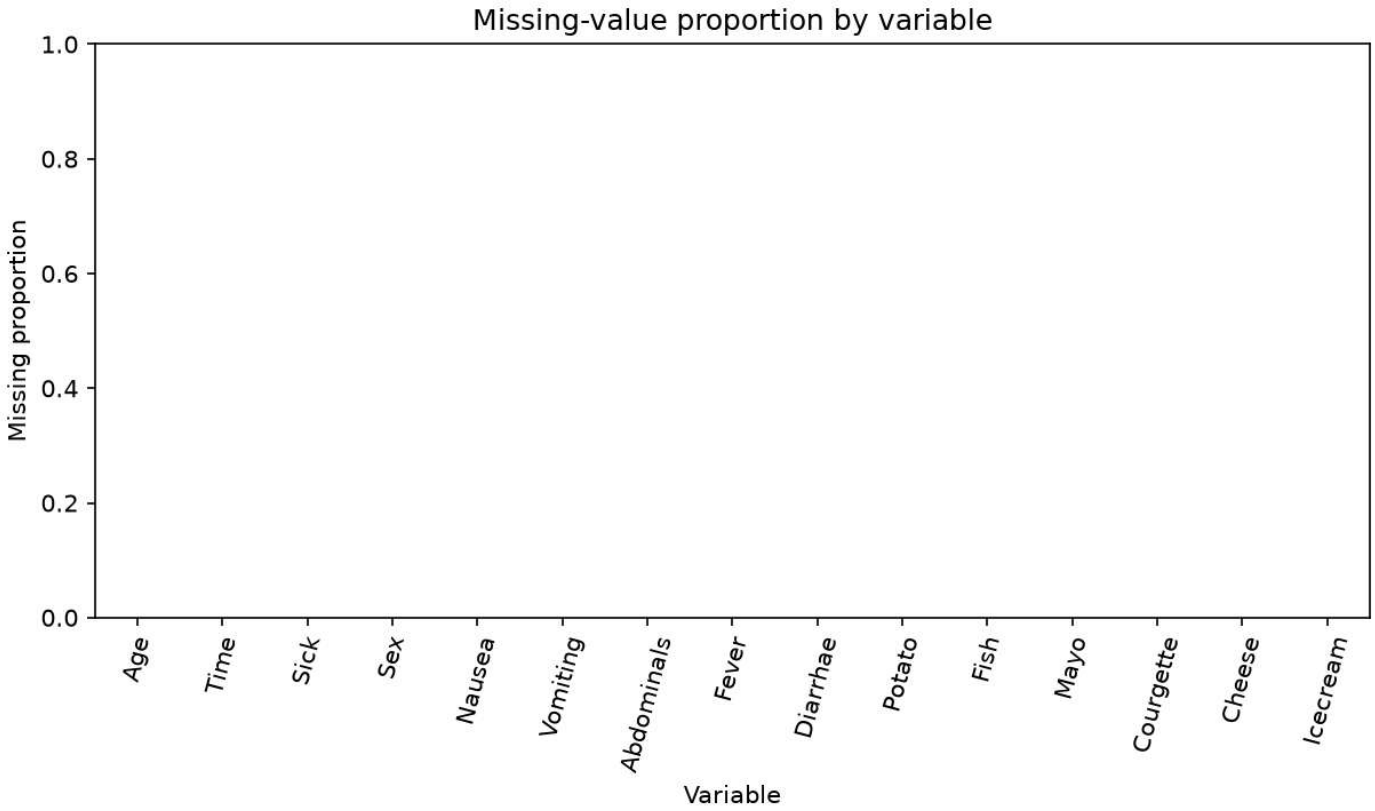
程式使用本報告附帶的 `data_visualization_template.py` 中缺失值與類別摘要函式；圖檔位於 `visualizations/`。摘要 CSV 亦一併輸出，便於重查數值。

3.2 1. 原始資料缺失值

分母為原始資料每欄 55 筆觀測值。15 個變數皆為 0 個缺失值（0.0%）。因為各欄缺失數皆為零，缺失矩陣不會增加資訊，故只呈現每欄比例圖。這些觀察不能用來判定 MCAR、MAR 或 MNAR。

變數	缺失數	缺失比例	非缺失數	分母
Age	0	0.0%	55	55
Time	0	0.0%	55	55
Sick	0	0.0%	55	55
Sex	0	0.0%	55	55
Nausea	0	0.0%	55	55
Vomiting	0	0.0%	55	55
Abdominals	0	0.0%	55	55
Fever	0	0.0%	55	55
Diarrhae (原始欄名)	0	0.0%	55	55
Potato	0	0.0%	55	55
Fish	0	0.0%	55	55
Mayo	0	0.0%	55	55
Courgette	0	0.0%	55	55
Cheese	0	0.0%	55	55
Icecream	0	0.0%	55	55

```
from outputs.data_visualization import load_data, make_missingness
original, cleaned = load_data()
missing = make_missingness(original)  # denominator: 55 rows per variable
```



原始資料各欄缺失比例

3.3 2. 清理版變數型態

依變數定義及實際值分類；整數儲存型態不代表連續尺度。Age 為以整數歲記錄的離散數值；Time 為單位未知的離散數值。其餘變數皆為二元名目類別。`_y` / `_n` 的是 / 否意義依使用者確認。

變數	統計型態	說明
Age	離散數值	整數年齡（歲）
Time	離散數值	整數 0–22；單位與意義未確認
Sick	二元名目類別	有病 / 沒病
Sex	二元名目類別	F / M
Nausea	二元名目類別	症狀是 / 否；細節依使用者指示不展開
Vomiting	二元名目類別	症狀是 / 否；細節依使用者指示不展開
Abdominals	二元名目類別	症狀是 / 否；細節依使用者指示不展開

變數	統計型態	說明
Fever	二元名目類別	症狀是 / 否；細節依使用者指示不展開
Diarrhea	二元名目類別	清理版欄名；原始欄名 `Diarrhae` 已修正
Potato、Fish、Mayo、Courgette、Cheese、Icecream	二元名目類別	有吃 / 沒吃

3.4 3. 單變量描述

3.4.1 3.1 離散數值變數

變數	n	平均	SD	最小	Q1	中位數	Q3	最大	偏度
Age（歲）	55	16.93	23.78	4	6	8	10	88	2.33
Time（單位未知）	55	10.16	7.80	0	0	12	16.5	22	-0.22

Age 多數集中在 4–11 歲（47/55，85.5%），另有 8 筆 36–88 歲紀錄，造成右偏；這與前階段記錄的來源描述差異相符，不能僅依分布判定為錯誤。Time 的 0 值有 17 筆，且都在 Sick_n 組；由於 Time 意義與單位未確認，僅作數值分布描述，不賦予時間解釋。

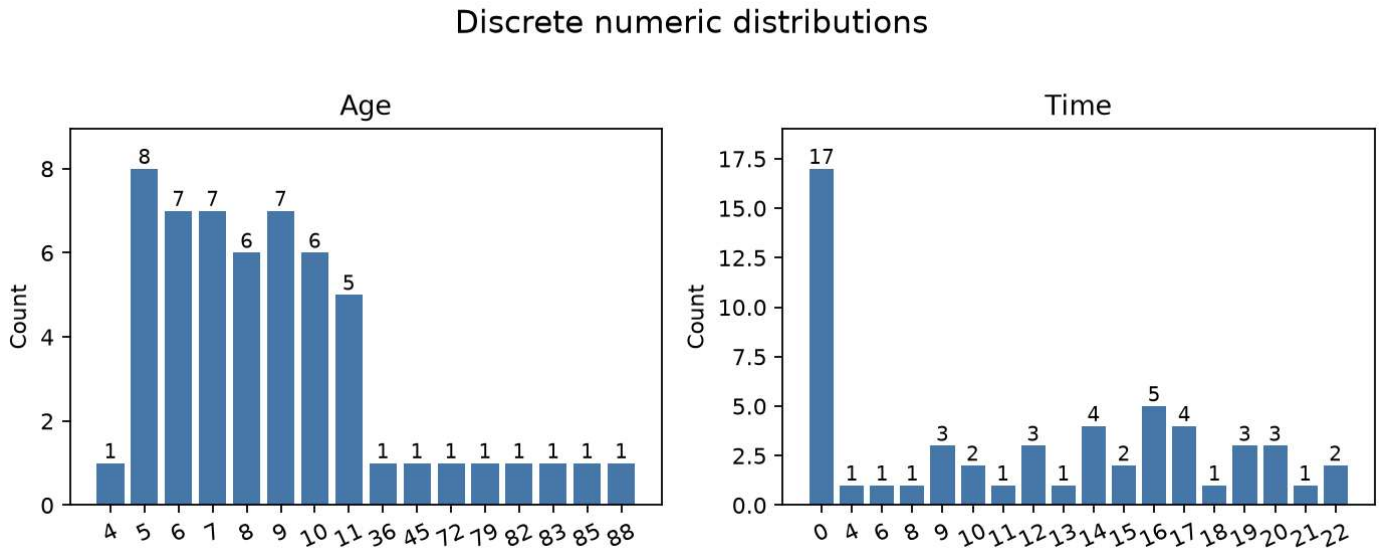
Age 頻數（每格為人數）：

年齡	4	5	6	7	8	9	10	11	36	45	72	79	82	83	85	88
人數	1	8	7	7	6	7	6	5	1	1	1	1	1	1	1	1

Time 頻數（每格為人數）：

Time	0	4	6	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22
人數	17	1	1	1	3	2	1	3	1	4	2	5	4	1	3	3	1	2

```
from outputs.data_visualization import make_univariate
numeric_summary, categorical_frequencies = make_univariate(cleaned)
```



Age 與 Time 的離散頻數

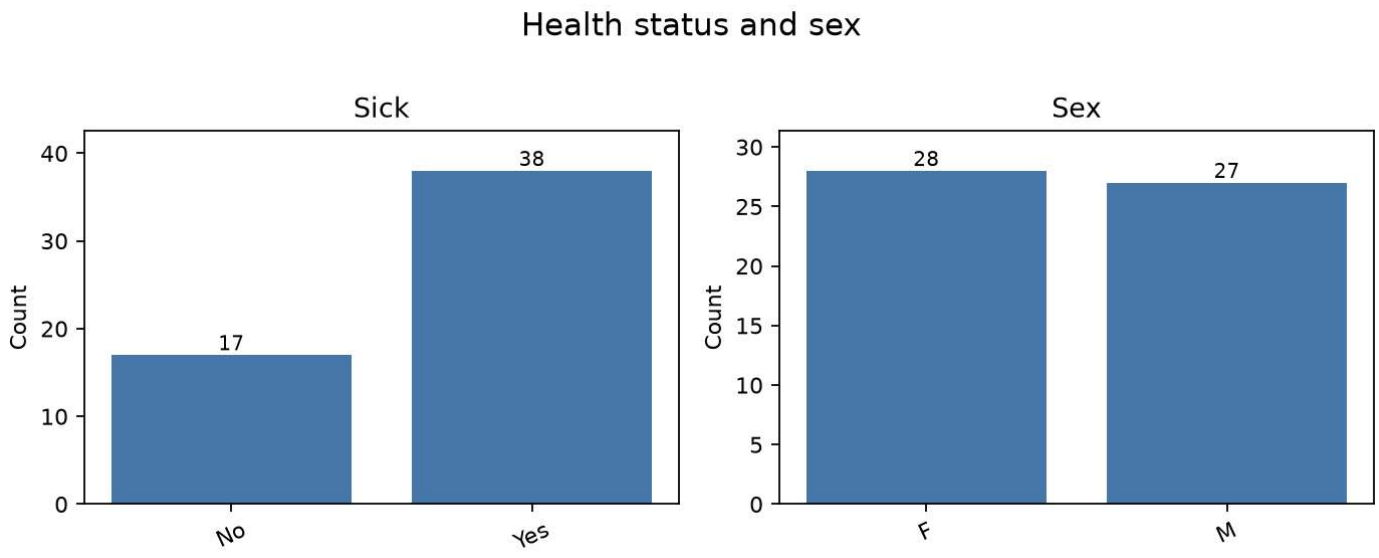
3.4.2 3.2 類別變數

下表為各類別人數及占 55 筆的百分比。食物欄的「有吃」比例均高，未吃組人數較少。

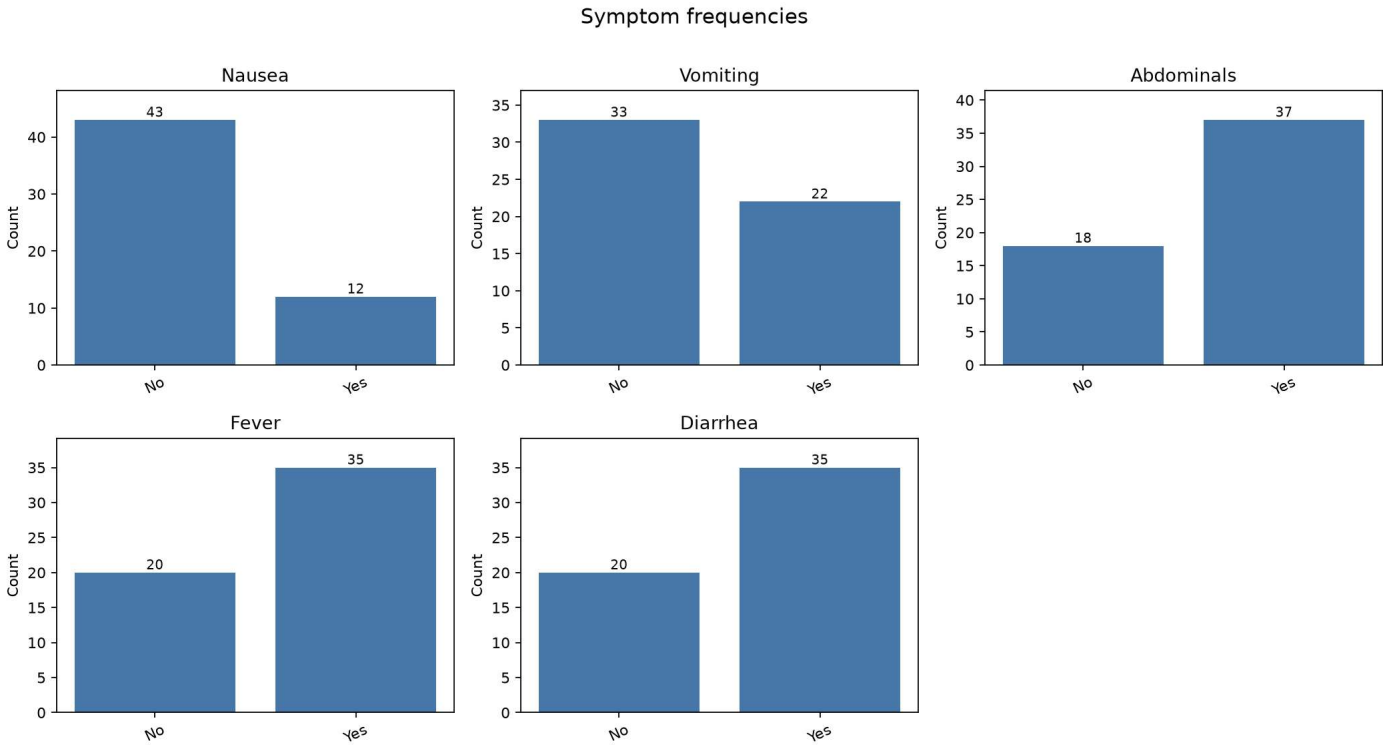
變數	類別	人數	百分比
Sick	沒病	17	30.9%
Sick	有病	38	69.1%
Sex	F	28	50.9%
Sex	M	27	49.1%
Nausea	否	43	78.2%
Nausea	是	12	21.8%
Vomiting	否	33	60.0%
Vomiting	是	22	40.0%
Abdominals	否	18	32.7%
Abdominals	是	37	67.3%
Fever	否	20	36.4%
Fever	是	35	63.6%
Diarrhea	否	20	36.4%
Diarrhea	是	35	63.6%

變數	類別	人數	百分比
Potato	沒吃	3	5.5%
Potato	有吃	52	94.5%
Fish	沒吃	1	1.8%
Fish	有吃	54	98.2%
Mayo	沒吃	10	18.2%
Mayo	有吃	45	81.8%
Courgette	沒吃	5	9.1%
Courgette	有吃	50	90.9%
Cheese	沒吃	7	12.7%
Cheese	有吃	48	87.3%
Icecream	沒吃	4	7.3%
Icecream	有吃	51	92.7%

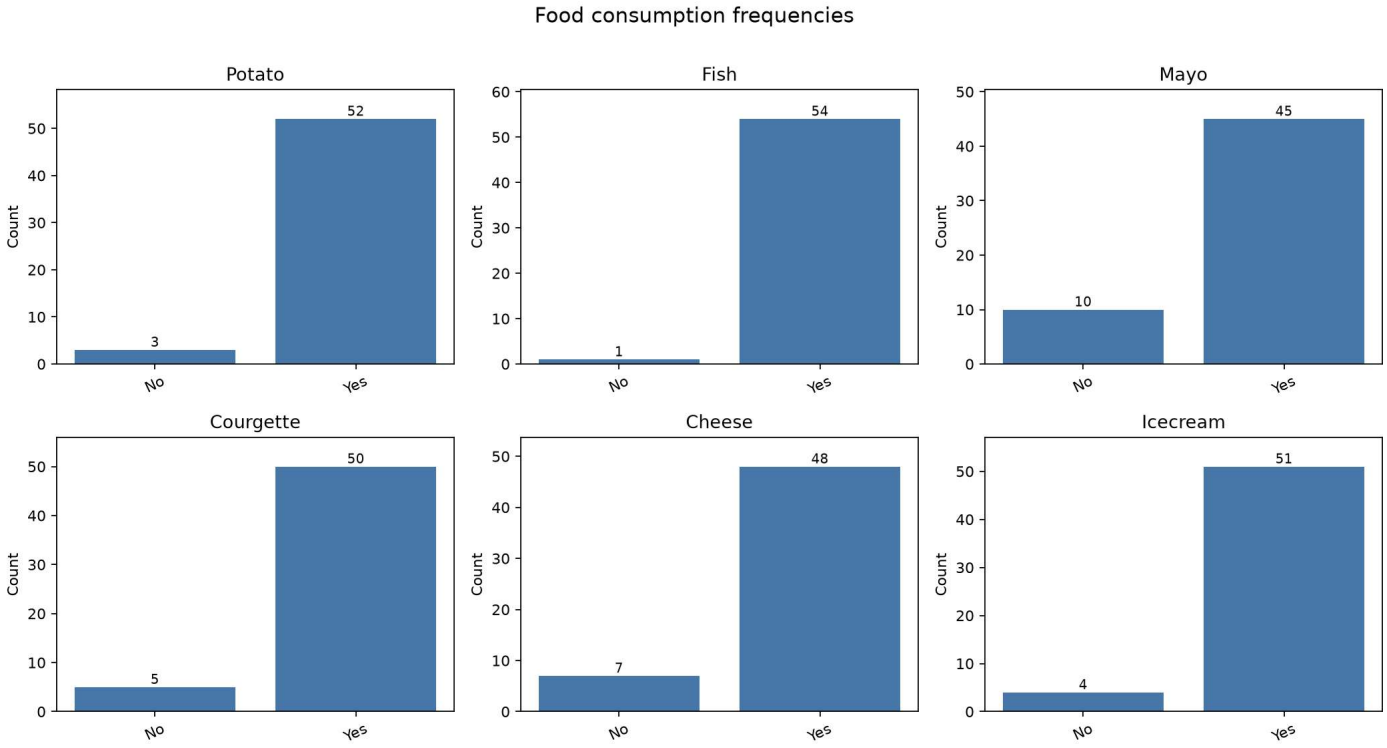
```
# make_univariate() above generates these count plots from the cleaned data.
from outputs.data_visualization import make_univariate
numeric_summary, categorical_frequencies = make_univariate(cleaned)
```



疾病狀態與性別頻數



症狀變數頻數



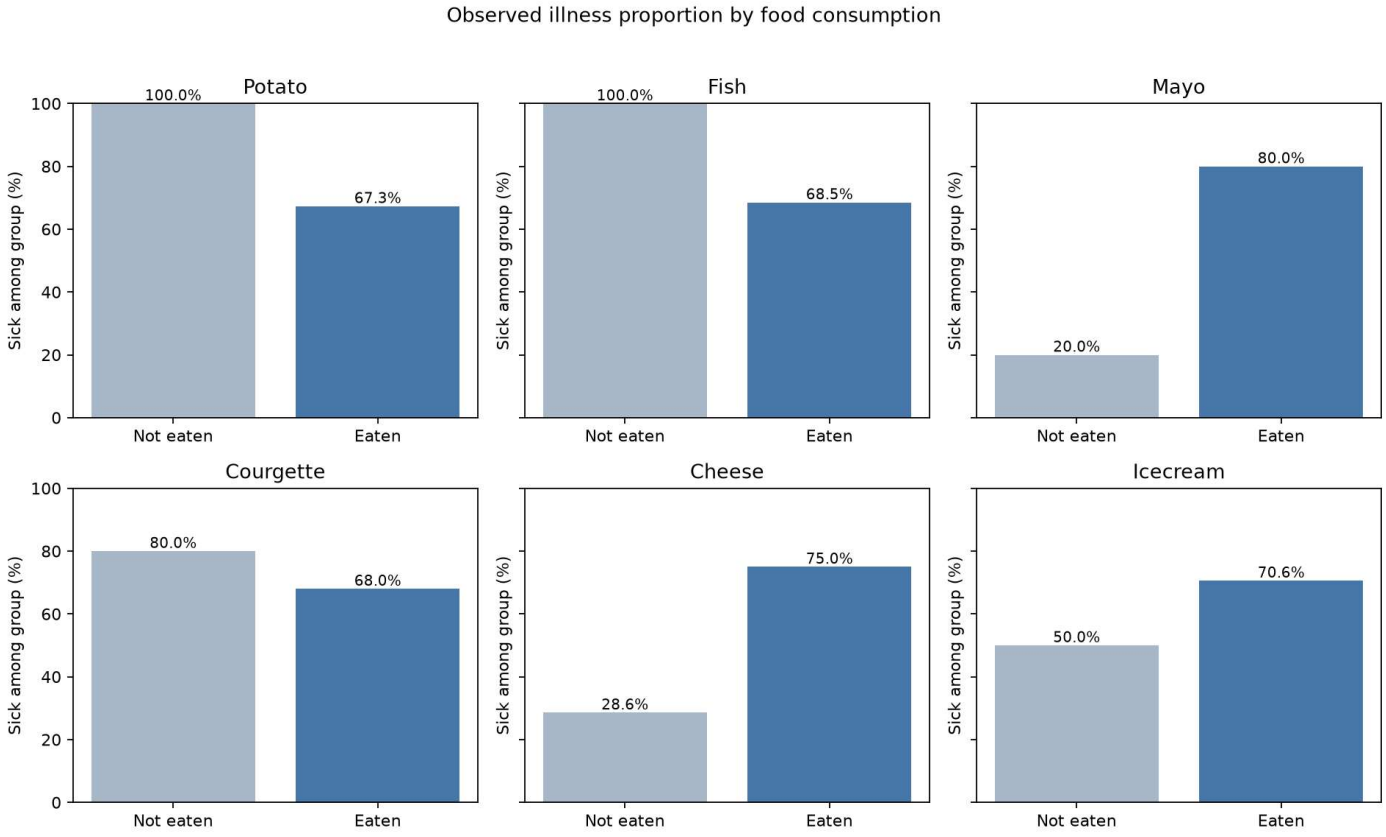
食物攝取頻數

3.5 4. 雙變量探索：食物攝取 × Sick

依資料說明，選擇 6 個食物欄位與 Sick 做列聯分析。每列的發病比例為該攝取組中 Sick_y 人數除以該組總人數。所有 2×2 表至少一格期望人數低於 5，因此使用雙尾 Fisher 精確檢定；不以 Pearson 卡方近似作可靠推論。p 值未作多重比較調整，僅供探索。

食物	沒吃：有病 / 總數（比例）	有吃：有病 / 總數（比例）	最小期望格數	檢定	p 值
Potato	3/3 (100.0%)	35/52 (67.3%)	0.93	Fisher exact	0.5445
Fish	1/1 (100.0%)	37/54 (68.5%)	0.31	Fisher exact	1.0000
Mayo	2/10 (20.0%)	36/45 (80.0%)	3.09	Fisher exact	0.0006
Courgette	4/5 (80.0%)	34/50 (68.0%)	1.55	Fisher exact	1.0000
Cheese	2/7 (28.6%)	36/48 (75.0%)	2.16	Fisher exact	0.0239
Icecream	2/4 (50.0%)	36/51 (70.6%)	1.24	Fisher exact	0.5795

```
from outputs.data_visualization import make_bivariate
food_results, food_tables = make_bivariate(cleaned)
```



各食物攝取組的觀察發病比例

未調整的探索性 p 值中，Mayo 與 Cheese 小於 0.05；然而未吃組樣本很少（例如 Fish 未吃組 n=1、Potato n=3），估計不穩定，且未處理六次比較的多重性。這些結果不證明食物造成疾病，也不構成最終方法選擇。食物可能共同食用，且抽樣 / 群聚設計資訊不足，故不作因果解讀。

3.6 5. 不適用或未執行的探索

- 沒有連續尺度變數，因此未產生連續變數散佈矩陣或相關熱圖；Age、Time 都按整數記錄，作離散數值描述。
- Time 欄不是已確認的日期或觀測時間索引，故不做時間序列分析，也不解讀其單位或起算點。
- 症狀細節依使用者指示暫不展開；沒有另做症狀間關聯檢定。
- 未建立或驗證統計模型；本階段結果僅為描述與探索。

3.7 6. 資料集概況與限制

- 樣本數 55；沒有缺失值。
- Sick_y 為 38/55（69.1%），Sick_n 為 17/55（30.9%）。
- 食物欄高度偏向有吃，部分未吃組極小，限制食物比較的精確度。
- Age 右偏，8 筆 36–88 歲值仍與資料來源描述不一致；本階段保留原值。
- Time 單位 / 定義未知；不能把它當作事件時間或日曆時間來建模。
- 資料是否有同一學校 / 群聚造成的相依性未知；完全相同的列依使用者決定視為不同受試者。
- 尚未指定正式研究問題、結果變數或解釋變數。相應的 `dataset_profile.json` 將研究目標與變數角色留空，僅標註樣本數較小的限制。

4 三、研究問題與方法選擇

4.1 1. 資料與研究方向摘要

- **使用者指定的分析方向**：主要分析食物攝取與症狀。Age 暫不納入目前問題；Time 保留在資料中，但本次先忽略。
- **候選研究問題**：在這 55 位受試者中，六種食物的攝取與五項記錄症狀是否相關？這裡先按「關聯」提出方法，不主張因果效果；是否有因果目標仍待確認。
- **候選解釋變數**：Potato、Fish、Mayo、Courgette、Cheese、Icecream，均為有吃 / 沒吃二元名目欄位。
- **候選結果變數**：Nausea、Vomiting、Abdominals、Fever、Diarrhea，均為是 / 否二元名目欄位。症狀細節依使用者指示暫不展開。
- **樣本與資料品質**：55 筆，沒有缺失值。完全相同的列依使用者決定視為不同受試者。清理版欄名已將 `Diarrhae` 修正為 `Diarrhea`。
- **稀疏程度**：食物未攝取組樣本數為 Fish 1、Potato 3、Icecream 4、Courgette 5、Cheese 7、Mayo 10。以六種食物×五項症狀形成 30 個 2×2 表檢查格數後，30 個表皆至少有一格期望人數 <5；10 個表另有觀察格數為 0。這支持優先考慮精確方法，但不會補足稀少組的資訊或提高估計精度。
- **研究設計與相依性**：受試者是否來自同一學校 / 同一食物中毒事件，及觀測值間是否有群聚相依，目前未知。

- **分析範圍**：Age 依指示排除；Time 保留但不納入方法比較。上一階段的食物× `Sick` 分析只是探索性結果，並未回答本階段的食物×症狀問題；本階段尚未計算這 30 個食物×症狀檢定的 p 值。

本步驟規範提到讀取 `data_visualization.qmd` ；上一階段依其指定輸出規範產生的是 `data_visualization.md` ，本提案以已核准的 Markdown 報告作為視覺化階段資料來源。

4.2 2. 已確認的研究問題與範圍

本次問題為探索六種食物攝取與五項症狀的類別共同模式。使用者已核准全部六種食物作為 active variables、全部五項症狀作為 supplementary variables；Age 排除，Time 保留但忽略。分析只作關聯探索，不作因果主張。群聚 / 抽樣設計仍未知，因此小樣本與食物未吃組稀少所造成的不穩定性需明確呈現。
3. 候選方法比較

候選方法	能回答的問題	與目前資料的吻合處	假設、診斷與資料需求	主要限制
逐一 2×2 Fisher 精確檢定 + Holm 多重檢定調整（優先候選）	對每個食物與每項症狀，檢查有吃 / 沒吃組的症狀比例是否不同；可同時報告勝算比、精確信賴區間及組別比例差。	兩欄皆為二元類別；全部 30 個預期列聯表都至少有一格期望數 <5，且 10 個有觀察零格，Pearson 卡方近似不合適。Fisher 精確法直接處理 2×2 稀疏表。Holm 可處理 30 個配對檢定的多重性。	需要受試者間獨立或有合理抽樣設計；若採 30 組檢定，須預先定義檢定家族。報告每組 2×2 人數、比例、勝算比及精確信賴區間，並呈現 Holm 調整後 p 值。	食物未吃組只有 1–10 人，估計與區間可能很寬或落在邊界；Fisher 檢定不會增加資訊，也不會調整其他共同攝取食物造成的混雜。檢定力可能偏低。
Firth 偏差修正 logistic regression（需要調整時的候選）	以每項症狀作二元結果，估計食物與該症狀的條件關聯；若事先合理指定，可同時納入多種食物以估計調整後關聯。	稀少格數可能造成普通 logistic regression 完全 / 準完全分離或極端估計；Firth 懲罰似然可減少偏差並處理分離下的無限係數問題。	需預先指定每項症狀的模型及調整變數；檢查分離、共同攝取食物間共線性、影響點、估計穩定性與信賴區間。若存在群聚，需另處理相依結構。	55 筆資料中同時放入六種食物可能過度擬合；多種食物可能共同攝取，且未吃組樣本極少。Firth 不能補回不存在的資訊，也不能自行解決混雜、研究設計或因果識別問題。

候選方法	能回答的問題	與目前資料的吻合處	假設、診斷與資料需求	主要限制
Multiple Correspondence Analysis（MCA）（探索性候選）	把多項二元食物與症狀同時放在低維圖上，探索常共同出現的類別 / 受試者輪廓。	全部變數為類別型，且現有 method taxonomy 已包含 MCA。	需選定哪些類別變數作為 active variables，並檢查慣量、類別貢獻與表示品質；對罕見類別作敏感度檢視。	屬探索性視覺化，不能取代逐一效應估計或假設檢定；Fish_n 僅 1 人等稀少類別可能主導座標，軸的解讀也不等同因果或統計顯著性。

4.2.1 優先提案

若研究目標是先找出哪些食物與哪些症狀呈現關聯，建議以 **30 組 Fisher 精確檢定、勝算比與精確信賴區間，並以 Holm 程序調整 p 值**作為主要候選。所有 30 個配對均稀疏，故不建議用一般 Pearson 卡方近似作主要檢定。結果應清楚標為探索性，並避免把關聯解讀為食物造成症狀。

如果你需要控制共同攝取的其他食物，才考慮 Firth logistic regression；不過以目前 n=55 及稀少暴露組，應先評估模型能否穩定估計，不能預設六食物同時調整一定可行。若你主要想看整體食物 / 症狀輪廓而非每對關聯，MCA 可作補充圖示。

使用者已選定 MCA 作為本次分析方法。本選擇適用於探索六項食物與五項症狀的共同類別模式；不表示 MCA 能估計因果效果或提供逐對檢定。其他候選方法未選用。

4.3 4. 方法文獻與適用意義

4.3.1 方法學文獻

1. Fisher, R. A. (1922). “On the Interpretation of χ² from Contingency Tables, and the Calculation of P.” *Journal of the Royal Statistical Society*, 85(1), 87–94. DOI: 10.1111/j.2397-2335.1922.tb00768.x. 此文是列聯表精確機率推論的基礎來源；本資料的稀疏 2×2 表使 Fisher 精確法成為比卡方近似更合適的候選。
2. Holm, S. (1979). “A Simple Sequentially Rejective Multiple Test Procedure.” *Scandinavian Journal of Statistics*, 6(2), 65–70. DOI: 10.2307/4615733. 提供逐步拒絕的多重檢定程序；此處可用來控制 30 個食物×症狀檢定的家族錯誤率。
3. Firth, D. (1993). “Bias Reduction of Maximum Likelihood Estimates.” *Biometrika*, 80(1), 27–38. DOI: 10.1093/biomet/80.1.27. 提出偏差修正估計，為 Firth logistic 候選的理論來源。
4. Heinze, G., & Schemper, M. (2002). “A Solution to the Problem of Separation in Logistic Regression.” *Statistics in Medicine*, 21(16), 2409–2419. DOI: 10.1002/sim.1047. 討論 logistic regression 分離問題，指出稀少且不平衡風險因子可能導致無限估計，並說明 Firth 程序可作為解法之一。
5. Greenacre, M. J. (1984). *Theory and Applications of Correspondence Analysis*. Academic Press. Google Books 書目. 書中涵蓋 correspondence analysis 與 multiple correspondence analysis，可支

援 MCA 作為類別資料探索與視覺化的候選。

4.3.2 類似應用例

Jirapanakorn, S., Wongsuwanphon, S., Jongcherdchootrakul, K., Thitichai, P., Yeesoonsang, S., & Jiraphongsa, C. (2024). "An Investigation of Food Poisoning Outbreak among Meeting Attendees in Pattaya City, Thailand, following Post-pandemic Kitchen Reopening, August 2022." *Outbreak, Surveillance, Investigation & Response (OSIR) Journal*, 17(2), 70–77. DOI: 10.59096/osir.v17i2.268235. 該研究以回溯性世代設計及 robust Poisson regression 評估食物與疾病關聯，是相似食安調查的應用例；其樣本、設計和病例結果不同，不足以證明該模型適合本資料。

4.4 5. 最終資料集 profile 與分析角色

`dataset_profile.json` 已更新為最終 MCA 設定：六種食物為 active variables，五項症狀為 supplementary variables；Age、Sex、Sick 排除，Time 保留但不分析。研究目標標記為探索性 association，樣本數 55，並記錄食物未吃類別稀少及群聚依賴未知的限制。 ## 6. Method taxonomy 狀態

`method_taxonomy.json` 維持原樣，沒有擴充；MCA 已有對應條目。 ### 最終使用者決定（取代本提案中的待確認狀態）

使用者已選定 MCA，並指定「食物設為 active、症狀設為 supplementary」。故本報告後續分析以六種食物決定座標空間，將五項症狀投影到既有空間；Age 不納入，Time 保留但忽略。使用者不同意擴張 `method_taxonomy`，該檔維持不變。這是探索性關聯分析，不估計因果效果。

5 四、MCA 分析

6 MCA 分析紀錄

6.1 分析設定

依使用者決定，採用 Multiple Correspondence Analysis（MCA），以六種食物變數作為主要變數（active），五項症狀作為補充變數（supplementary）。食物類別決定分析維度；症狀類別投影至食物所形成的空間，不參與維度建構。Age、Sex、Sick 不納入本分析；Time 保留但忽略。`method_taxonomy.json` 未擴充。

分析單位為受試者，完全相同的列仍依使用者先前決定視為不同受試者。資料來自已核准的 `poison_cleaned.parquet`（55 筆）。MCA 使用 Burt 方法。MCA 是探索性視覺化，不是顯著性檢定或因果模型；圖上的相對方向不能當成效果大小或因果證據。

6.2 步驟 1：資料與類別檢查

每列是一位受試者，每欄是一個類別變數。六個 active 食物欄位均有「有吃 / 未吃」兩類；五個症狀欄位均有「有 / 無」兩類。資料沒有缺失值。稀少食物類別頻數為 Fish_n=1、Potato_n=3、Icecream_n=4、Courgette_n=5、Cheese_n=7、Mayo_n=10。Fish_n 尤其稀少，可能形成不穩定且偏離原點的座標。

6.2.1 程式碼：套件、讀檔與欄位設定

```
library(FactoMineR)
library(factoextra)
library(vcd)
library(arrow)
library(ggplot2)

data <- as.data.frame(arrow::read_parquet("poison_cleaned.parquet"))
foods <- c("Potato", "Fish", "Mayo", "Courgette", "Cheese", "Icecream")
symptoms <- c("Nausea", "Vomiting", "Abdominals", "Fever", "Diarrhea")
selected <- data[, c(foods, symptoms), drop = FALSE]
selected[] <- lapply(selected, factor)
stopifnot(nrow(selected) == 55, all(complete.cases(selected)))
```

執行結果：55 位受試者、6 個食物主要變數、5 個症狀補充變數；均為二元類別，無缺失值。食物未吃類別頻數如上，分析保留所有類別，對稀少類別座標作審慎解讀。

6.3 步驟 2：食物與症狀的描述性關聯前檢視

Cramér's V 衡量兩個類別變數整體關聯，範圍 0–1；它沒有方向，也不代表因果。30 個食物 - 症狀配對數值介於 0.014–0.475；較大的係數有 Mayo–Abdominals（0.475）、Mayo–Fever（0.428）、Mayo–Diarrhea（0.428）、Cheese–Abdominals（0.315）。由於部分未吃組很小，這些係數可能不穩定；沒有依任意門檻判為弱、中或強，也不作顯著性推論。完整數值見 `mca_cramers_v_food_symptom.csv`。

6.3.1 程式碼：計算食物 - 症狀 Cramér's V

```
cv <- matrix(NA_real_, nrow = length(foods), ncol = length(symptoms),
             dimnames = list(foods, symptoms))
for (food in foods) {
  for (symptom in symptoms) {
    cv[food, symptom] <- vcd::assocstats(
      table(data[[food]], data[[symptom]])
    )$cramer
  }
}
round(cv, 3)
```

```
          Nausea Vomiting Abdominals Fever Diarrhea
Potato     0.261    0.196      0.168 0.015    0.182
Fish       0.072    0.111      0.095 0.103    0.103
Mayo       0.249    0.289      0.475 0.428    0.428
```

```
Courgette  0.014    0.258      0.086 0.108    0.108
Cheese     0.202    0.200      0.315 0.278    0.278
Icecream   0.022    0.086      0.103 0.079    0.079
```

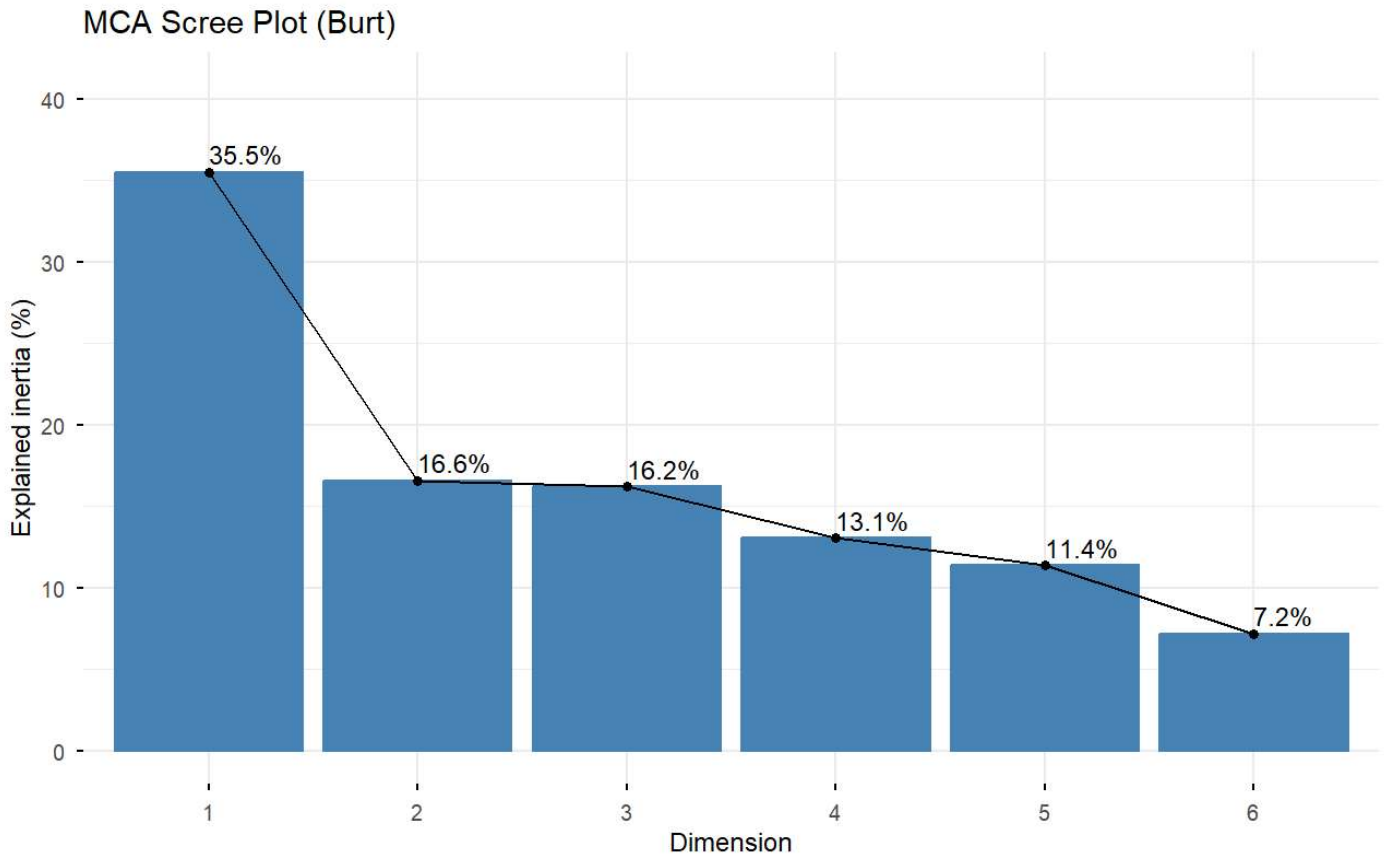
執行結果：30 個係數範圍為 0.014–0.475；主要數值列於步驟 2，完整矩陣見 `mca_cramers_v_food_symptom.csv`。這是執行 MCA 前的描述性資訊，不是篩選 MCA 的門檻。 ## 步驟 3：執行 MCA 並檢視維度

```r
res.mca <- FactoMineR::MCA(
  selected,
  quali.sup = 7:11,
  method = "Burt",
  ncp = 5,
  graph = FALSE
)
round(res.mca$eig, 4)
```

```
      eigenvalue percentage of variance cumulative percentage of variance
dim 1     0.0631                35.5267                           35.5267
dim 2     0.0295                16.6006                           52.1273
dim 3     0.0288                16.2149                           68.3422
dim 4     0.0233                13.0969                           81.4390
dim 5     0.0202                11.3704                           92.8094
dim 6     0.0128                 7.1906                          100.0000
```

執行結果：

維度	解釋慣量 (%)	累積 (%)
1	35.53	35.53
2	16.60	52.13
3	16.21	68.34
4	13.10	81.44
5	11.37	92.81
6	7.19	100.00



MCA 陡坡圖

第一維高於其餘維度；第二、三維解釋慣量相近，後續維度也沒有明顯斷崖。因此不能只靠前兩維完整代表食物類別結構。第二維雖可畫在平面圖上，但幾乎被極少數未吃類別主導；下方會分開說明。第一至第三維可作探索性檢視，但低維圖仍只是整體結構近似。

6.3.2 程式碼：食物類別座標、貢獻與 cos²

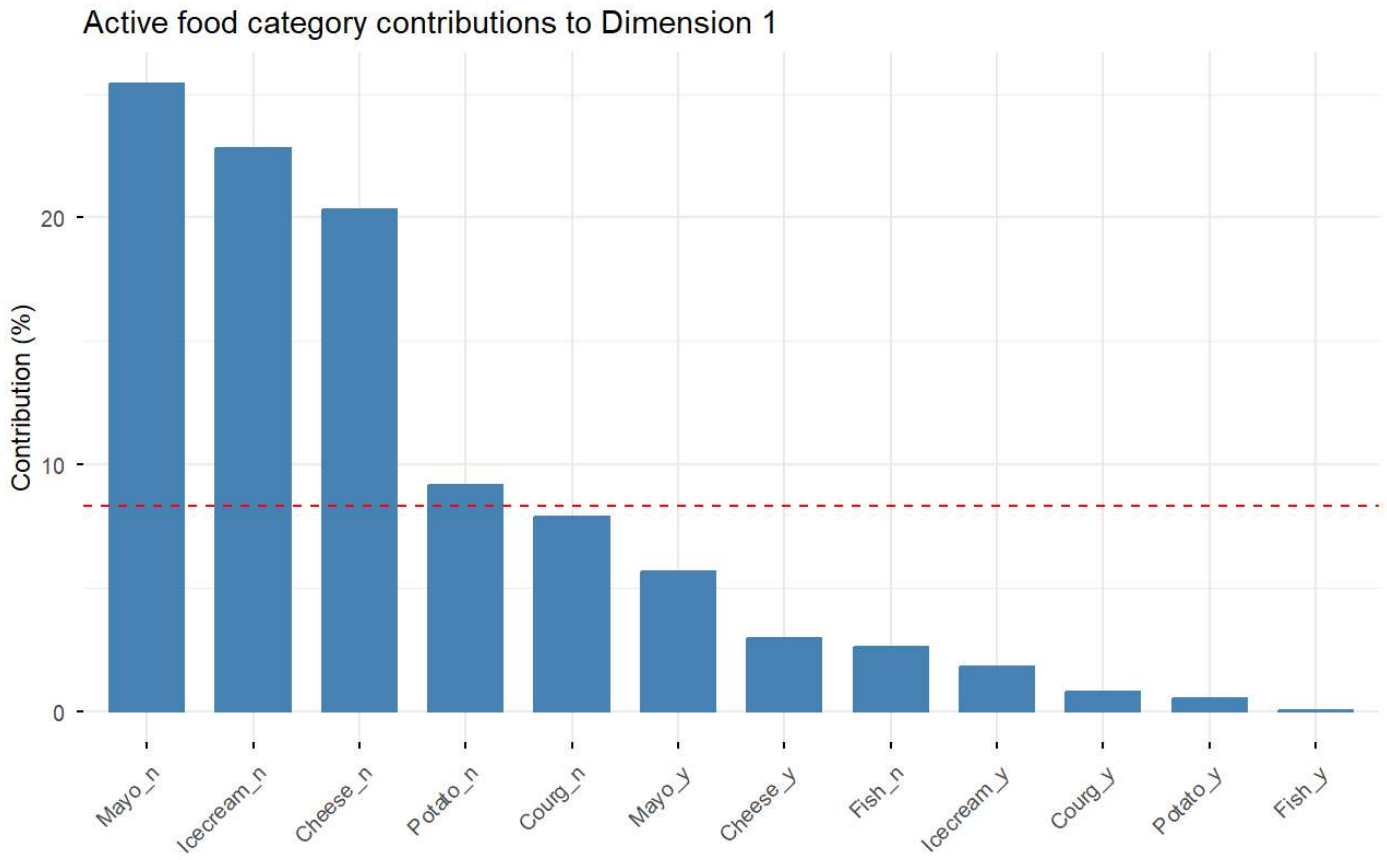
```
round(data.frame(
  coord = res.mca$var$coord[, 1:3, drop = FALSE],
  contribution = res.mca$var$contrib[, 1:3, drop = FALSE],
  cos2 = res.mca$var$cos2[, 1:3, drop = FALSE]
), 3)
```

	coord.Dim.1	coord.Dim.2	coord.Dim.3	contribution.Dim.1
Potato_n	-0.798	-1.030	-0.004	9.170
Potato_y	0.046	0.059	0.000	0.529
Fish_n	-0.734	2.480	-0.303	2.586
Fish_y	0.014	-0.046	0.006	0.048
Mayo_n	0.728	-0.054	-0.339	25.442
Mayo_y	-0.162	0.012	0.075	5.654
Courg_n	0.572	0.076	1.064	7.872
Courg_y	-0.057	-0.008	-0.106	0.787
Cheese_n	0.778	-0.051	-0.379	20.345
Cheese_y	-0.113	0.007	0.055	2.967
Icecream_n	1.089	-0.042	0.381	22.811

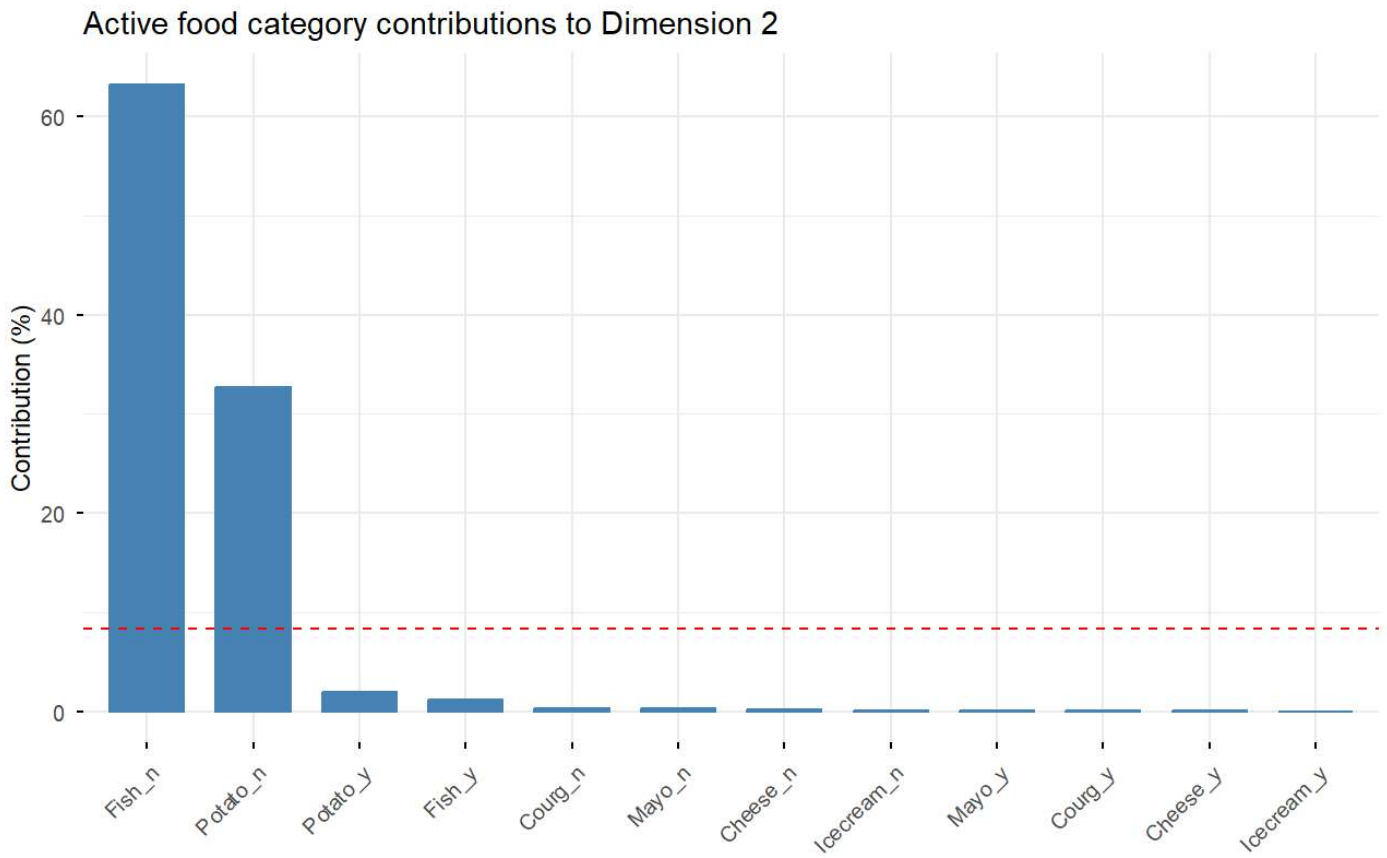
```
Icecream_y      -0.085       0.003      -0.030              1.789
           contribution.Dim.2 contribution.Dim.3 cos2.Dim.1 cos2.Dim.2
Potato_n               32.701              0.001      0.213      0.355
Potato_y                1.887              0.000      0.213      0.355
Fish_n                 63.261              0.968      0.059      0.676
Fish_y                  1.172              0.018      0.059      0.676
Mayo_n                  0.296             12.109      0.625      0.003
Mayo_y                  0.066              2.691      0.625      0.003
Courg_n                 0.297             59.548      0.190      0.003
Courg_y                 0.030              5.955      0.190      0.003
Cheese_n                0.187             10.564      0.487      0.002
Cheese_y                0.027              1.541      0.487      0.002
Icecream_n              0.072              6.125      0.511      0.001
Icecream_y              0.006              0.480      0.511      0.001
           cos2.Dim.3
Potato_n        0.000
Potato_y        0.000
Fish_n          0.010
Fish_y          0.010
Mayo_n          0.136
Mayo_y          0.136
Courg_n         0.655
Courg_y         0.655
Cheese_n        0.115
Cheese_y        0.115
Icecream_n      0.063
Icecream_y      0.063
```

主要結果（貢獻度是相對於該維度的百分比）：

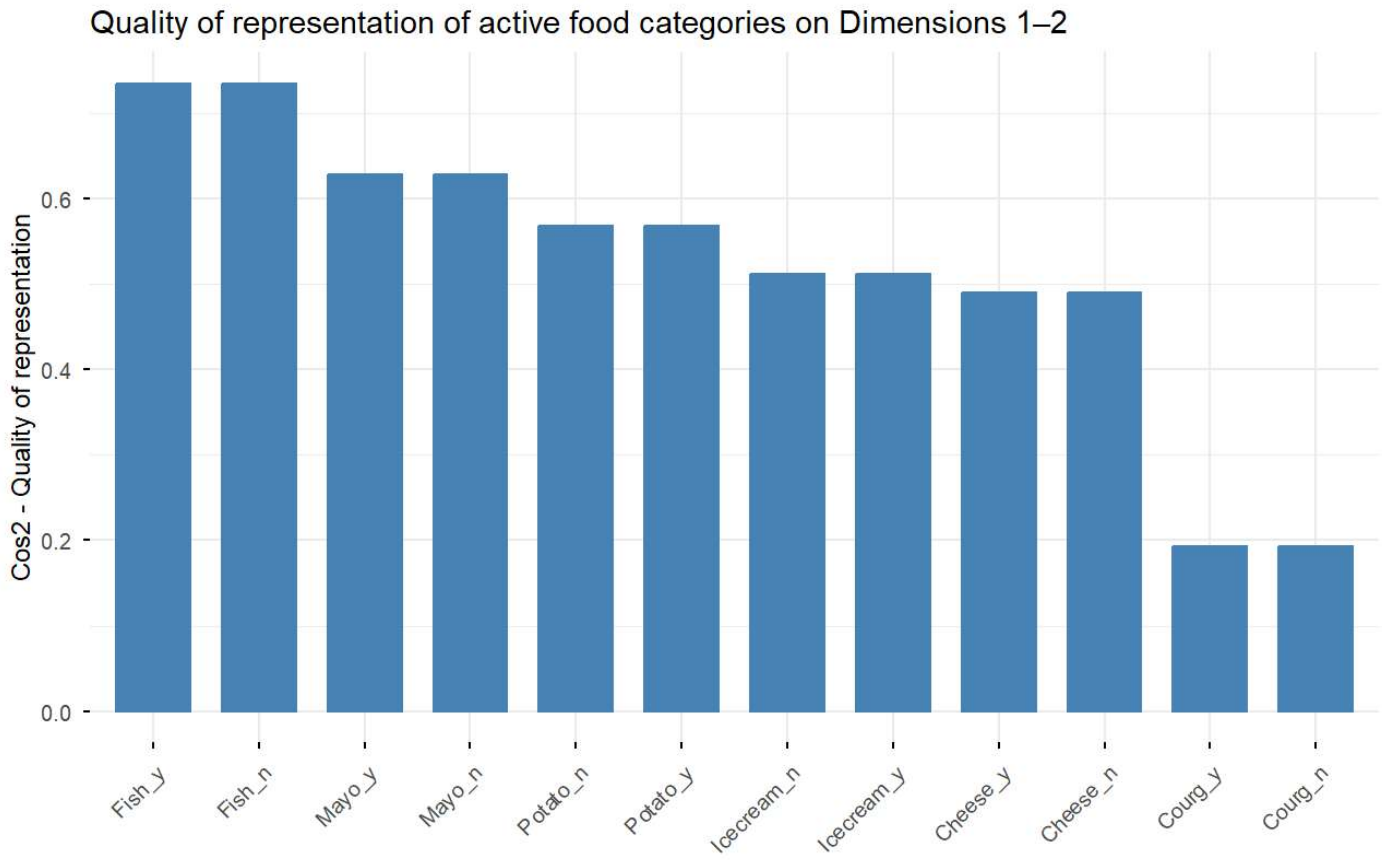
- **維度 1**：主要由 Mayo_n（25.44%）、Icecream_n（22.81%）、Cheese_n（20.34%）、Potato_n（9.17%）及 Courgette_n（7.87%）構成。它主要呈現各食物未吃類別的不同組合；Mayo、Icecream、Cheese、Courgette 未吃類別位於 Dim1 正向，Potato_n 則在負向。這不是一條一致的「所有食物未吃」軸，不能合併解讀成單一飲食型態。
- **維度 2**：Fish_n 貢獻 63.26%，Potato_n 貢獻 32.70%，合計約 95.96%。Fish_n 僅 1 人、Potato_n 僅 3 人，因此 Dim2 幾乎由稀少類別決定；不建議把它解讀為可普遍化的食物模式。
- **維度 3**：Courgette_n 貢獻 59.55%；該類別只有 5 人。此維度同樣受小類別明顯影響，需保留解讀。



食物類別對第一維的貢獻



食物類別對第二維的貢獻



食物類別在前兩維的 cos²

cos² 衡量類別在指定維度中的表示品質，不是關聯強度或貢獻度。Fish 類別在 Dim1 的 cos² 僅 0.059，在 Dim2 為 0.676；這反映 Fish 類別主要沿第二維分離，但該軸受單一 Fish_n 個案主導。Potato 類別在 Dim2 的 cos² 為 0.355。低維座標對稀少類別尤其敏感。

6.4 步驟 4：將症狀投影到食物空間

```
round(res.mca$quali.sup$coord[, 1:3, drop = FALSE], 3)
```

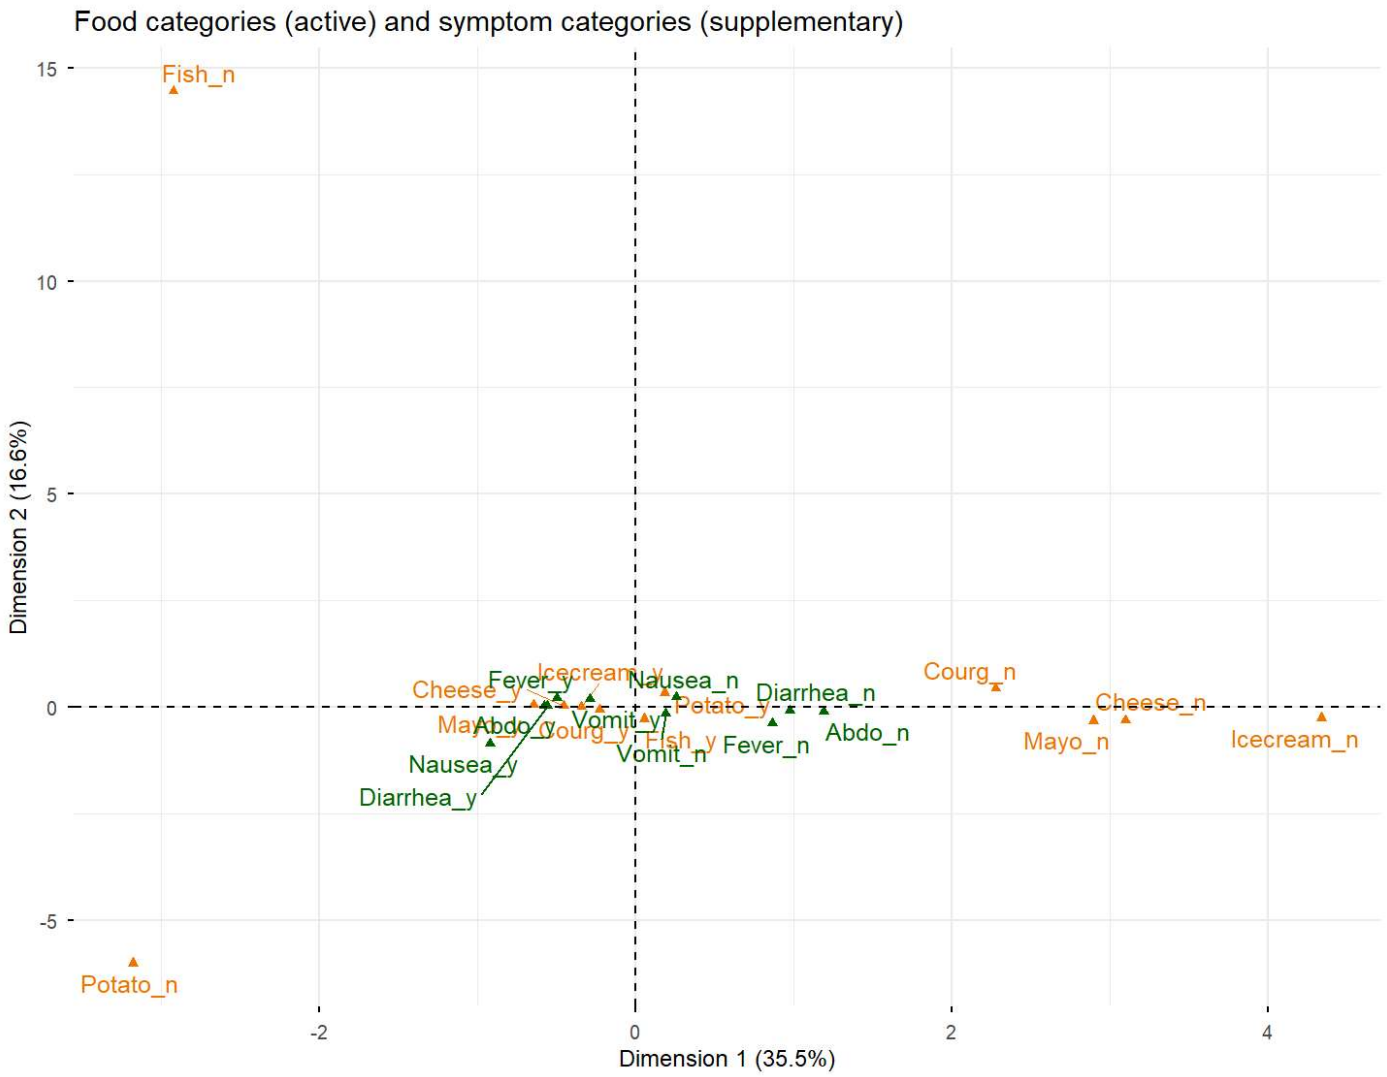
```
            Dim 1  Dim 2  Dim 3
Nausea_n    0.065  0.041 -0.036
Nausea_y   -0.231 -0.145  0.129
Vomit_n     0.048 -0.023 -0.126
Vomit_y    -0.073  0.035  0.190
Abdo_n      0.299 -0.017 -0.190
Abdo_y     -0.145  0.008  0.093
Fever_n     0.217 -0.065 -0.172
Fever_y    -0.124  0.037  0.098
Diarrhea_n  0.245 -0.012 -0.171
Diarrhea_y -0.140  0.007  0.098
```

```
round(res.mca$quali.sup$cos2[, 1:3, drop = FALSE], 3)
```

```
            Dim 1 Dim 2 Dim 3
Nausea_n    0.507 0.201 0.158
Nausea_y    0.507 0.201 0.158
Vomit_n     0.085 0.020 0.579
Vomit_y     0.085 0.020 0.579
Abdo_n      0.686 0.002 0.279
Abdo_y      0.686 0.002 0.279
Fever_n     0.559 0.050 0.349
Fever_y     0.559 0.050 0.349
Diarrhea_n 0.640 0.002 0.313
Diarrhea_y 0.640 0.002 0.313
```

症狀不參與軸的建構，只根據其類別在受試者中的分布投影至食物空間。第一維上五個「有症狀」類別都在負向；四個「無症狀」類別在正向（Vomiting_n 接近原點且略為正向）。這可描述為症狀有 / 無類別沿第一維呈現大致相反方向，但不能據此說某種食物造成症狀。從食物座標看，Mayo_y、Courgette_y、Cheese_y、Icecream_y 稍偏負向，而相應的未吃類別偏正向；Potato、Fish 的類別排列不同。這是一個初步投影模式，不足以給出單一食物的風險排序。

在 Dim1 上，Abdominals、Diarrhea、Fever 的症狀類別投影表示品質較高（各自 $\cos^2$ 約 0.686、0.640、0.559）；Nausea 約 0.507。Vomiting 約 0.085，故其在第一維平面上的位置代表性較差。Dim2 對症狀投影的表示品質普遍低；而 Dim2 又受 Fish_n 與 Potato_n 主導，因此不應依據 Dim2 對症狀作實質解讀。



食物主要類別與症狀補充類別投影圖

圖中從原點看同方向可作為可能共同模式的線索；類別點的距離與方向不等於關聯強度或因果效果。尤其圖中 Fish_n、Potato_n 位置遠，主要反映極小頻數，不能過度解讀。

6.5 結論與限制

本次 MCA 顯示食物未吃類別形成若干不同方向，症狀有 / 無投影主要沿第一維呈現大致相反方向。不過第一維沒有形成所有食物一致的未吃 / 有吃軸；第二維受 Fish_n（1 人）和 Potato_n（3 人）支配，第三維也受 Courgette_n（5 人）影響。因此目前適合作為探索性描述，不能據此判斷個別食物是否增加症狀風險，也不能替代列聯表推論或適當的統計模型。若要正式量化食物與症狀關聯，需要另行進行推論分析，並處理稀少類別帶來的不確定性。

完整程式碼在 `mca_analysis.R`；分析使用的 R `renv` 專案環境位於專案根目錄，數值結果分別存於 `mca_eigenvalues.csv`、`mca_active_category_metrics.csv` 與 `mca_symptom_projection.csv`。